



ÉCOLE NATIONALE SUPÉRIEURE
D'INFORMATIQUE ET D'ANALYSE DES SYSTÈMES

DATA-DRIVEN DECISION MAKING
OLIST BRAZILIAN E-COMMERCE DATASET 2016–2018

Plan Expérimental A/B Test : Réduction des Avis Négatifs par l'Amélioration des Délais de Livraison

Élèves :

Rim BADDOU
Aya ESUBAI
Oumaima EL ANSARI

Encadrant :

Pr.Y. TABII

Contexte et Justification

L'analyse SHAP du modèle Random Forest (AUC-ROC = 0,730) identifie `delay_days` comme le premier facteur prédictif des avis négatifs (score ≤ 2), avec une importance moyenne absolue de 0,142. Le test de Mann-Whitney confirme une différence hautement significative de satisfaction entre livraisons à temps et en retard ($p \approx 0$, médiane : 5,0 vs 1,0).

Taux actuel d'avis négatifs : 12,7% des commandes livrées | **Taux de retard** : 8,3% des commandes

Formulation des Hypothèses

Intervention testée : Mise en place d'alertes automatiques vendeurs à J+1 de dépassement du délai estimé, couplée à une notification proactive client avec nouveau délai estimé.

H₀ (Hypothèse nulle) : L'intervention n'a aucun effet sur le taux d'avis négatifs. $\pi_{\text{contrôle}} = \pi_{\text{traitement}}$

H₁ (Hypothèse alternative) : L'intervention réduit significativement le taux d'avis négatifs. $\pi_{\text{traitement}} < \pi_{\text{contrôle}}$

Paramètres Statistiques

Hypothèses de calcul

- Taux de base : $p_0 = 12,7\%$
- Effet minimum détectable : $\Delta = -3,2$ pp (soit $p_1 = 9,5\%$, réduction relative de 25%)
- Niveau de signification : $\alpha = 0,05$ (bilatéral)
- Puissance statistique : $1 - \beta = 80\%$
- Test : proportion z-test bilatéral

Calcul de la taille d'échantillon

La formule appliquée est :

$$n = \frac{\left(z_{\alpha/2} \sqrt{2\bar{p}(1-\bar{p})} + z_{\beta} \sqrt{p_0 q_0 + p_1 q_1} \right)^2}{(p_0 - p_1)^2}$$

où $\bar{p} = (p_0 + p_1)/2 = 11,1\%$, $z_{\alpha/2} = 1,96$, $z_{\beta} = 0,84$.

Résultat : $n = 1512$ commandes par groupe (3 024 au total) | À raison de 957 commandes/semaine, **durée estimée** : 4 semaines (marge de sécurité incluse)

Protocole Expérimental

Randomisation	Attribution aléatoire au niveau de la commande (hash de <code>order_id</code> modulo 2)
Groupe Contrôle	Processus actuel sans modification — 1 512 commandes
Groupe Traitement	Alerte vendeur à J+1 + notification client proactive — 1 512 commandes
Périmètre	Commandes avec statut prévu "en retard" selon l'estimé de livraison
Exclusions	Commandes annulées, remboursées, ou sans avis soumis à 7 jours
Isolation	Un client ne peut appartenir aux deux groupes simultanément

Métriques de Suivi

Type	Métrique	Définition	Cible
Primaire	Taux d'avis négatifs	% commandes avec score ≤ 2 sur les commandes livrées	< 9,5%
Primaire	Score de satisfaction moyen	Moyenne de <code>review_score</code> sur les commandes de l'expérience	> 4,10
Secondaire	Taux de résolution anticipée	% commandes en retard ayant reçu une alerte vendeur dans les délais	> 80%
Secondaire	Délai moyen de résolution	Jours entre dépassement estimé et livraison effective	Réduction de 20%
Garde-fou	Taux de contact client	% clients ayant contacté le support (proxy satisfaction)	Pas de hausse

Les métriques sont mesurées à J+7 après livraison pour garantir la soumission de l'avis.

Estimation de l'Impact Financier et Opérationnel

Impact direct — Satisfaction

- Réduction de 3,2 pp du taux d'avis négatifs
- Score moyen projeté : 4,18 / 5 (vs 4,09 actuel)
- Amélioration NPS proxy estimée : +8 points

Impact indirect — Rétention

- Les avis ≥ 4 multiplient par 2,3 la probabilité de rachat
- Gain estimé : +1,5% de taux de rétention
- Clients supplémentaires fidélisés : $\approx 1\,440$ / an

Impact financier projeté

- Panier moyen : R\$ 154,11
- Commandes annuelles concernées : $\approx 54\,700$
- Commandes à avis négatif évitées : $\approx 1\,750$ / an
- Gain de CA estimé (effet rétention) : **R\$ 40 000 / an**

Coût de l'intervention

- Développement alertes : charge ponctuelle
- Coût opérationnel marginal : $\approx$ R\$ 0 (automatisé)
- ROI estimé : positif dès le 2^e mois

Calendrier et Décision

Phase	Durée	Actions
Préparation	1 semaine	Développement alertes, pipeline randomisation, baseline KPIs
Expérimentation	4 semaines	Collecte des données, monitoring quotidien des métriques de garde-fou
Analyse	1 semaine	Test statistique, analyse des segments, calcul d'impact
Décision	—	Déploiement global si $p < 0,05$ et effet dans le sens attendu

Règle d'arrêt anticipé : Si le taux de contact support augmente de plus de 2 pp dans le groupe traitement lors des deux premières semaines, l'expérience est interrompue et le déploiement est annulé dans l'attente d'une révision du protocole.